Agenthon 2026 Track 2

V9 모델 개발 및 검증 보고서

Text-Gated Probabilistic Mixture-of-Experts

Team: lifeisluck
Development status: V9.1-R submission candidate / pending sealed result
Prepared: 2026-10-08

보고서 범위

V8 에서 V9 로의 구조 전환, V9 C/R/S 구조, sealed Development 비교, state 별 분포 연구, Repricing(R) 심화 검증, state transition 및 numeric prior 실험, 그리고 V9.1-R production 후보까지의 의사결정을 한 문서에 정리한다.

Executive Summary

V9 의 핵심 아이디어는 LLM 이 미래 숫자를 직접 예측하도록 하지 않고, 텍스트를 시장 상태(state)를 판별하는 soft router 로 사용하는 것이다. 숫자 데이터는 각 state 에서 실제 predictive distribution 의 크기와 모양을 생성한다. 이 역할 분리는 V8 의 text-conditioned 구조를 더 안정적인 형태로 재설계한 것이다.

항목	결론
현재 production backbone	V9 v0.2 - C/R/S text-gated probabilistic mixture
Sealed 비교	V8 Text-ON rerun -2.3537 -> V9 -2.2382, 약 4.9% 개선
Continuation (C)	공식 Gaussian continuation 유지
Repricing (R)	현재 R0 보다 direction + joint-shape weighted R2 가 local expert test 에서 강함
Shock (S)	현재 extreme empirical 유지; Student-t/weighted extreme 대안은 악화
Volatility (V)	별도 state 의 존재는 확인되나 별도 expert 로는 아직 이득 없음
State transition	previous state / transition memory / recent change 추가는 악화
Numeric prior	개선폭이 약 1-2%에 그쳐 사전 승격 기준 미달; router 는 text-led 로 유지
다음 sealed 실험	V9.1-R: R0 -> R2 만 교체한 controlled submission

한 줄 결론

V9 는 유지한다. 모델을 더 복잡하게 만들기보다, House 가 판별한 Repricing state 안에서 R distribution 을 개선하는 V9.1-R 을 단일 변경점으로 sealed 검증한다.

목차

1. 문제 설정과 V9 가 필요했던 이유
2. V9 의 전체 구조: C / R / S + House router
3. State 별 predictive distribution
4. Joint distribution 은 어떻게 보존하는가
5. V9 v0.2 구조 검증과 sealed 결과
6. State distribution 연구: C / R / V / S
7. Repricing(R) 심화 검증과 robust-shrink 실험
8. 언제 state 를 바꿀 것인가: transition 연구
9. Current numeric prior 실험
10. V9.1-R production 후보
11. 현재까지의 의사결정과 다음 단계
Appendix. 실험 레지스트리 및 해석 주의사항

1. 문제 설정과 V9 가 필요했던 이유

1.1 Track 2 평가 구조

Track 2 의 underlying composite 는 세 요소로 구성된다.

```
Composite = 0.5 * Marginal CRPS
          + 0.3 * Joint Variogram
          + 0.2 * Tail Penalty
```

따라서 좋은 모델은 단일 평균 예측이 아니라, 각 자산의 marginal distribution, 여러 자산의 공동 움직임, 그리고 극단 tail 을 동시에 합리적으로 만들어야 한다.

1.2 V8 에서 확인된 문제

V8 은 House 가 텍스트를 읽고 scenario probabilities, asset 별 shift, volatility scale 을 조절하는 multivariate block-bootstrap 구조였다. Text-ON 성능은 강했지만, Text-OFF backbone 이 약했다. 즉 House 가 사실상 분포 중심을 움직이는 주된 엔진이 되어 있었다.

- V8 Text-OFF backbone: de-meaned / no-drift block bootstrap 이 sealed 에서 약함.
- V8 Text-ON 은 House 가 분포 중심과 scale 을 상당히 움직여 성능을 회복.
- 따라서 V9 에서는 안정적인 numerical prior 를 먼저 고정하고, text 는 state selection 역할로 제한.

1.3 점수 체계 변경과 재비교

Development 도중 leaderboard normalization 이 변경되어 과거 scale 의 점수와 새 점수를 직접 비교할 수 없게 되었다. 이를 해결하기 위해 동일한 V8 Text-ON 을 새 환경에서 다시 실행해 비교 기준을 재설정했다.

실험	Score	해석
V8 Text-ON (old run)	-0.9993	구 scoring scale. 새 점수와 직접 비교 금지
V8 Text-OFF	-2.4718	새 환경에서 text 없는 backbone
V8 Text-ON rerun	-2.3537	새 환경에서 V8 controlled baseline
V9 Text-Gated	-2.2382	새 환경에서 V8 Text-ON 대비 약 4.9% 개선

새 환경 기준으로 V8 Text-OFF -> V8 Text-ON 은 약 4.8% 개선, V8 Text-ON -> V9 는 약 4.9% 추가 개선, Text-OFF -> V9 는 약 9.5% 개선이었다.

2. V9 의 전체 구조: C / R / S + House router

V9 는 score component 별로 Marginal 모델, Joint 모델, Tail 모델을 따로 만드는 방식이 아니다. 먼저 미래 시장을 몇 개의 latent state 로 나누고, state 마다 전체 joint predictive distribution 의 형태를 다르게 만든다.

```
Text corpus
    |
    v
House -> state evidence / direction / confidence
    |
    v
Deterministic router -> (pi_C, pi_R, pi_S)
    |
    +---- C: Continuation distribution
    +---- R: Repricing distribution
```

```
   +---- S: Shock distribution
   |
   v
Final joint predictive draws
```

2.1 House 의 역할

House 는 미래 가격이나 금리를 직접 맞히지 않는다. 텍스트에서 다음과 같은 ordinal evidence 만 추출한다.

- repricing_evidence: -2 ~ +2
- shock_evidence: -2 ~ +2
- confidence
- affected_assets 별 direction (-1 / 0 / +1)과 strength (1 / 2)
- pattern / horizon 관련 정성 정보

그 뒤 deterministic router 가 family 별 cap 과 evidence 를 이용해 C/R/S mixture weight 를 만든다. 즉 Text 는 state detector/router 이고, numerical history 는 실제 분포 생성 엔진이다.

2.2 Soft state, not hard switch

V9 는 하나의 state 로 hard switching 하지 않는다. 예를 들어 F2 에서 강한 repricing evidence 가 있어도 C 37%, R 63%처럼 확률 질량을 나누어 여러 plausible future 를 동시에 유지한다.

```
Example: 1000 draws
C = 37% -> 370 continuation draws
R = 63% -> 630 repricing draws
S =  0% ->   0 shock draws
```

3. State 별 predictive distribution

3.1 C - Continuation

Continuation 은 모델의 안전판이다. 현재 level 을 anchor 로 하고 과거 volatility 와 correlation 을 사용한 multivariate Gaussian random walk 를 사용한다.

```
Delta Y_h ~ N(0, Sigma * h)

핵심 역할: 특별한 text signal 이 없거나 House 가 실패했을 때 안정적인 prior 제공
```

V8 의 약한 block-bootstrap backbone 대신 공식 reference 에 가까운 Gaussian continuation 을 사용한 것이 V9 의 중요한 구조적 변경이다.

3.2 R - Repricing

Repricing 은 단순히 분산이 커지는 상태가 아니라 distribution center 가 한쪽으로 이동하는 상태다. House 가 affected-assets direction 을 제공하면, 과거 standardized joint move 중 그 방향과 맞는 historical episodes 를 후보 pool 로 사용한다.

V9 R0 는 방향 일치가 확인된 historical joint episodes 에서 empirical sampling 을 한다. 개별 asset 을 따로 뽑지 않고 한 시점의 전체 벡터를 함께 가져온다.

3.3 S - Shock

Shock 은 평범한 Gaussian variation 으로 설명하기 어려운 extreme event 를 담당한다. historical standardized joint move 의 extremeness 상위 10%를 Shock 전용 pool 로 예약한다.

초기 V9 에서는 Repricing 이 extreme events 까지 흡수해 12-13 sigma mean shift, 20 배 이상의 SD 가 발생하는 문제가 있었다. v0.2 에서 R 과 S 를 분리해 이 폭주를 제거했다.

3.4 왜 R/S 를 parametric distribution 하나로 고정하지 않았나

C 는 Gaussian 이지만 R 과 S 는 historical empirical distribution 을 사용한다. Repricing 과 Shock 의 cross-asset shape 를 parametric distribution 하나에 억지로 압축하기보다, 실제 관측된 joint vector 를 보존하는 것이 이 단계의 설계 목적이었다.

4. Joint distribution 은 어떻게 보존하는가

Joint 는 각 asset 의 marginal 을 따로 잘 맞히는 문제가 아니라, 같은 draw 안에서 여러 자산이 경제적으로 일관된 방식으로 함께 움직이는가의 문제다.

```
Bad independent draw example
2Y  +40bp
5Y  -30bp
10Y +50bp
30Y -40bp

V9 joint draw
state = Repricing
2Y  +1.5 sigma
5Y  +1.3 sigma
10Y +0.8 sigma
30Y +0.4 sigma
```

V9 에서는 draw 마다 하나의 global expert state 를 선택하고, 해당 historical episode 의 전체 asset vector 를 같이 사용한다. 따라서 2Y 는 Shock, 5Y 는 Continuation 처럼 asset 별로 서로 다른 state 를 섞지 않는다.

> **Joint 의 핵심**
> 같은 draw index 가 하나의 시장 시나리오가 되도록 유지한다. 이것이 F3 Variogram 을 위한 기본 설계 원칙이다.

5. V9 v0.2 구조 검증과 sealed 결과

5.1 103-unit structural validation

항목	V9 v0.2 결과
Units	103 / 103 pass
Family	F1 23 / F2 27 / F3 22 / F4 31
Monthly fallback	4
Repricing active	99 / 103
Shock active	29 / 103
Distribution changed under mock	99 / 103
Max mock |mean shift|	약 2.13 OFF-sd
Max mock SD ratio	약 2.19x

V9 v0.2 는 초기 extreme-R 문제를 제거한 뒤 모든 public unit 에서 구조적으로 통과했다. 이후 Docker/offline/Linux gate 도 5/5 통과했다.

5.2 Sealed Development evidence

모델	새 scoring 환경 Score	V8 Text-ON 대비
V8 Text-OFF	-2.4718	-5.0% 수준
V8 Text-ON rerun	-2.3537	baseline
V9 Text-Gated	-2.2382	약 +4.9%

이 결과로 V9 는 현재 production backbone 으로 채택되었다. 다만 이 점수만으로 V9 내부의 어떤 요소가 개선을 만들었는지는 알 수 없기 때문에, 이후 local pseudo-OOS 연구를 통해 state distribution 과 router complexity 를 분해했다.

6. State distribution 연구: C / R / V / S

6.1 4-state taxonomy 진단

V9 이후에는 C/R/S 외에 방향은 불명확하지만 uncertainty 가 높은 V(Volatility/Uncertainty) state 를 별도 후보로 검토했다. 588 historical pseudo-OOS folds 에서 base taxonomy 는 다음 비중을 보였다.

State	Base share	Loose	Strict	해석
C	61.6%	56.6%	67.9%	정상 continuation 이 대다수
R	1.0%	2.7%	0.9%	희소하지만 방향성 repricing
V	23.1%	26.4%	24.1%	빈도가 충분해 별도 연구 가치 있음
S	14.3%	14.3%	7.1%	극단 / shock state

V 는 loose/strict 에서도 약 24% 수준으로 유지되어 state 자체의 존재는 확인되었다. 그러나 "state 가 존재한다"와 "별도 expert distribution 이 production 에 유용하다"는 별개의 문제다.

6.2 Distribution tournament

State	Best candidate	Median ratio	Win rate	p90	판정
R	R2 direction + shape	0.635	100%	0.923	강한 신호, 표본 확대 필요
V	V2 empirical high-vol	1.001	50%	1.369	별도 expert 승격 안 함
S	S0 current empirical	0.997	50%	5.181	현재 방식 유지, 복잡화 금지

V 에서 Student-t 와 scaled Gaussian 은 더 나빴고, S 에서도 weighted extreme empirical 과 Student-t 는 악화되었다. 따라서 production 변경 후보는 R 에 집중하기로 했다.

7. Repricing(R) 심화 검증과 robust-shrink 실험

7.1 R0 -> R2 아이디어

현재 R0 는 House direction 과 맞는 historical episodes 를 후보로 둔 뒤 비교적 고르게 sampling 한다. R2 는 direction 뿐 아니라 cross-asset joint shape 가 더 유사한 episode 에 높은 weight 를 주는 conditional empirical expert 다.

```
R0: direction-filtered empirical
R1: weighted direction
R2: direction + joint-shape weighted empirical
```

7.2 Deep validation

2,705 historical folds 를 분류한 deep validation 에서 repricing fold 는 base 22, loose 63, strict 16 개였다. R2 는 Gaussian continuation 에 대한 absolute quality 가 강했다.

Taxonomy	R2 vs Gaussian median	Win rate	p90	Worst

Base	0.385	100.0%	0.857	0.913
Loose	0.386	96.8%	0.869	1.100
Strict	0.277	100.0%	0.825	0.986

그러나 R2 와 현재 R0 의 paired comparison 은 median 에서는 매우 강했지만 p90 이 base 1.90, loose 2.00 수준으로 불안정했다. 또한 clean-direction test 는 historical realized future 로 만든 oracle coarse direction 을 사용하므로 House routing accuracy 를 증명하지 않는다.

7.3 Robust-shrink 가설

R2 의 불안정성이 일부 historical episodes 에 weight 가 과도하게 집중되기 때문이라는 가설을 검증하기 위해 fixed 50% shrink 와 ESS-adaptive shrink 를 테스트했다.

후보	Base median vs R0	Base p90	Loose median	Loose p90	결론
R2 full	0.348	1.979	0.369	2.014	중앙 성능 강함, paired tail 불안정
R2 shrink50	0.380	1.393	0.445	1.535	p90 완화 but gate 미달
R2 ESS adaptive	0.348	1.979	0.369	2.014	R2 full 과 사실상 동일

ESS 진단에서 R2 의 effective sample size 가 오히려 R0 보다 컸고 adaptive alpha 가 1.0 으로 유지되었다. 즉 R2 불안정성이 단순 weight concentration 때문이라는 가설은 기각되었다.

> **R 연구의 현재 결론**
>
> R2 는 absolute predictive distribution 으로는 매우 강한 후보다. 단순 shrink 는 해결책이 아니며, 실제 House direction 과 결합했을 때 transfer 되는지는 sealed submission 으로 확인해야 한다.

8. 언제 state 를 바꿀 것인가: transition 연구

두 번째 핵심 질문은 state distribution 자체가 아니라 "언제 C/R/S 를 바꿀 것인가"였다. 이전 state, 최근 변화량, persistence 를 넣으면 state switching 을 안정화할 수 있다는 가설을 5,095 transition folds 에서 검증했다.

모델	설명	Mean Brier	Mean Log-loss	Top-1
P0	Unconditional prior	0.5168	0.9110	64.7%
P1	Current state only	0.5090	0.9198	65.5%
P2	Previous -> Current pair	0.5278	0.9740	63.3%
P3	Pair + recent change	0.5369	1.0296	63.4%

P2/P3 는 P1 보다 악화되었다. 따라서 explicit state memory, transition path, recent-change prior 를 production router 에 추가하지 않기로 했다.

- Previous-state memory: reject
- Explicit transition matrix: reject

- Recent-change prior: reject
- Complex hysteresis / Markov-style router: 현재 단계에서는 reject

9. Current numeric prior 실험

State transition memory 가 실패한 뒤에는 더 단순한 질문을 검증했다. "현재 numerical state 자체가 House evidence 앞에 약한 prior 로 들어갈 가치가 있는가?"를 3,870 folds, 94 units, grouped 5-fold CV 로 테스트했다.

모델	Brier	Log-loss	Brier ratio vs N1	Log-loss ratio
N1 family + current state	0.4945	0.8734	1.0000	1.0000
N2 continuous numeric	0.4866	0.8685	0.9840	0.9944
N3 50/50 shrink	0.4877	0.8655	0.9862	0.9910

N2/N3 는 약 1-2% 정도의 개선은 있었지만 사전에 정한 production gate 를 통과하지 못했다. 특히 R-state one-vs-rest Brier 는 N3 에서 1.0017 로 미세하게 악화되었다. 따라서 numeric prior 는 넣지 않고 router 를 text-led 로 유지하기로 했다.

> **복잡도를 줄인 최종 결정**
>
> V9 router 에는 previous state, transition memory, recent change, continuous numeric prior 를 추가하지 않는다. House evidence + family caps + 기존 deterministic mapping 을 유지한다.

10. V9.1-R production 후보

Local 연구 결과를 production 에 반영할 때 한 번에 하나의 가설만 바꾸기 위해 V9.1-R 은 Repricing expert 만 변경한다.

구성 요소	V9	V9.1-R
Continuation C	Gaussian continuation	동일
Repricing R	R0 direction-filtered empirical	R2 direction + joint-shape weighted
Shock S	Extreme empirical	동일
House prompt / JSON	기존	동일
Router / family caps	기존	동일
Fallback	기존	동일

10.1 V9.1-R structural validation

항목	결과
Units discovered	103
Passed / Failed	103 / 0
Family counts	F1 23 / F2 27 / F3 22 / F4 31
Monthly fallback	4

Repricing active	99 / 103
Shock active	29 / 103
Distribution changed under mock	99 / 103
Max mock |mean shift|	2.09 OFF-sd
Max mock SD ratio	2.10x
Docker/offline/Linux gate	5 / 5 PASS

R2 를 production 에 넣었지만 초기 V9 에서 발생했던 10-sigma 급 폭주는 재발하지 않았다. 구조상 distribution shift 와 scale 은 V9 v0.2 의 안전 범위와 유사하다.

10.2 Sealed Development #7 의 질문

Controlled experiment

V9.1-R submission 의 유일한 질문은 "현재 V9 의 R0 를 R2 로 교체하면 sealed Development 에서도 score 가 개선되는가?"이다. 결과가 좋아지면 R expert 개선의 transfer 로 해석할 수 있고, 악화하면 oracle-direction local gain 이 실제 House routing 에서는 옮겨가지 않은 것으로 본다.

11. 현재까지의 의사결정과 다음 단계

연구 항목	상태	현재 결정
V9 architecture	KEEP	현재 production backbone
C Gaussian continuation	KEEP	안전판 유지
R2 direction+shape	TEST SEALED	V9.1-R 에서 controlled 검증
R shrink50 / ESS shrink	STOP	중앙 gain 희생, p90 gate 미달
V separate expert	HOLD	state 존재는 확인, expert 성능은 없음
S complex alternatives	STOP	Student-t / weighted extreme 악화
Transition memory	STOP	P2/P3 악화
Current numeric prior	STOP	개선폭 작고 preset gate 미달

11.1 V9.1-R 결과별 다음 행동

Sealed 결과	판단	다음 단계
V9.1-R 가 V9 보다 명확히 개선	R2 transfer 성공	R2 채택. 다음은 House direction/confidence calibration 연구
거의 동일	R distribution gain 이 제한적	V9 유지 또는 R2 보수 채택 검토. 새 구조 실험은

		별도
악화	Local oracle gain transfer 실패	R0 복귀. distribution 보다 House repricing detection 품질을 우선 연구

11.2 현재 V9 의 가장 단순한 해석

```
Text -> House -> soft state evidence

C: stable Gaussian continuation
R: text-conditioned historical repricing distribution
S: historical extreme joint distribution

No explicit state memory
No numeric prior
No separate V expert (yet)
```

지금까지의 연구는 모델을 복잡하게 만드는 방향보다, 불필요한 구성 요소를 제거하고 실제로 transfer 가능성이 있는 한두 요소만 남기는 방향으로 수렴했다. 이는 제출 횟수가 제한된 Development 단계에서 특히 중요하다.

Appendix. 실험 레지스트리 및 해석 주의사항

A. 주요 실험 레지스트리

실험	표본 / 환경	핵심 결과	결정
V8 rerun	Sealed Dev	-2.3537	새 scoring 기준 baseline
V9	Sealed Dev	-2.2382	Backbone 채택
V9 local suite	588 folds	V state 23.1%, R2 강한 초기 신호	R deep validation
R deep validation	2,705 folds	R2 absolute quality 강함, paired p90 불안정	Shrink 가설 검증
R robust shrink	3,893 folds	Shrink 로 p90 일부 완화, gate 미달	R2 full 후보 유지
State transition	5,095 transitions	P2/P3 약화	Memory / change reject
Current-state calibration	3,870 folds / 94 units	Numeric prior 약 1-2% 개선	Production 에 미추가
V9.1-R structural	103 units + Docker 5/5	모든 gate pass	Sealed #7 후보

B. Local 연구 해석 시 주의사항

- Pseudo-OOS local score 는 official leaderboard score 가 아니다.
- R expert 연구의 clean-direction test 는 historical realized future 로 만든 oracle coarse direction 을 사용한다. 따라서 expert distribution quality 를 분리해 측정하지만 House routing alpha 를 증명하지 않는다.
- State taxonomy 는 연구용 label 이며, production 입력으로 미래 값을 사용하지 않는다.
- Sealed Development 결과가 local 연구보다 우선한다. Local 개선이 sealed 로 transfer 되지 않은 전례가 이미 있었다.
- 한 번에 하나의 가설만 바꾸는 controlled submission 원칙을 유지한다.

C. Source / artifact basis

본 보고서는 다음 프로젝트 산출물과 실행 로그를 기준으로 작성되었다: V9 local research suite summary, V9 Repricing deep validation summary, V9 R2 robust-shrink validation summary, state transition model output, V9 current-state calibration summary, V9/V9.1 structural validation logs, CodaBench Development submission scores, official Track 2 scoring/submission documentation.

Prepared for internal model development and submission decision-making. This document is not an official competition report.