AGENTHON 2026
TRACK 2 QUANT CANDIDATE

개발 진행 리포트

Gaussian baseline 에서 regime-aware bootstrap 실험까지
QRM 관점에서 이해하는 모델 구조, 검증 방식, ablation 결과

작성 기준일: 2026-09-28

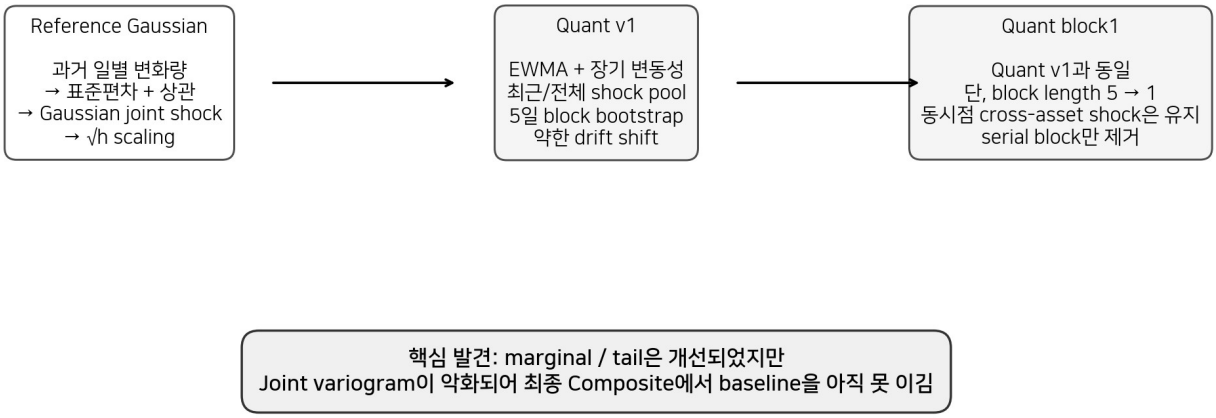
대상 독자: Python 구현보다 확률·통계·리스크 모델링에 익숙한 QRM 배경

1. 한 페이지 요약

지금까지 한 일의 핵심은 "기존 Gaussian random-walk baseline 을 그대로 쓰는 대신, 최근 시장의 변동성 regime 과 fat-tail 을 더 잘 반영하는 Quant 모델을 만들고, 과거 여러 시점에서 walk-forward 방식으로 baseline 과 비교한 것"이다.

현재 결론은 명확하다. 새 Quant 모델은 개별 자산의 확률분포(Marginal CRPS)와 tail calibration 에서 baseline 보다 좋아졌지만, 자산 간 공동 움직임을 평가하는 Joint variogram 에서 손해를 보면서 최종 Composite score 에서는 아직 baseline 을 이기지 못했다.

항목	현재 상태
공식 제출 형식	admissible = true, g0~g3 전부 pass
Baseline	Reference Gaussian random walk
Quant v1	EWMA volatility + recent/full mixture + multivariate block bootstrap + 약한 drift
검증	24-fold walk-forward, spacing 21, 1,000 Monte Carlo draws
현재 best Quant	quant_block1 (block length 5 → 1)
핵심 성과	Marginal -3.2%, Tail -19.7% vs reference
핵심 문제	Joint +5.1% 악화 → Composite 는 reference 보다 +2.2% 높음 (나쁨)
다음 방향	좋은 marginal/tail 을 유지하면서 correlation/dependence 를 안정화하는 Quant v2



이 문서에서는 Python 코드를 줄 단위로 설명하기보다, 각 코드가 통계적으로 어떤 모형을 구현하는지와 그 결과가 왜 그렇게 나왔는지를 중심으로 정리한다.

2. 대회의 예측 문제와 평가 함수

Track 2 는 하나의 점 예측(point forecast)을 맞히는 문제가 아니다. 여러 자산과 horizon 에 대해 Monte Carlo draws 를 제출하고, 실제 관측값이 나왔을 때 "분포 전체가 얼마나 잘 맞았는가"를 평가한다. 따라서 평균만 맞는 모델보다 불확실성, 상관구조, tail 을 함께 잘 모델링해야 한다.

$$\mathbf{S = 0.5 \times Marginal\ CRPS + 0.3 \times Joint\ Variogram + 0.2 \times Tail\ Penalty}$$

모든 항은 낮을수록 좋다. Joint 가 30%라서 dependence error 가 상당히 비싸다.

2.1 Marginal CRPS - 개별 자산의 분포가 맞는가

$$\mathbf{CRPS(F,y) = E|X-y| - \tfrac{1}{2}\,E|X-X'|}$$

직관적으로는 "실제값 y 주변에 forecast distribution 이 얼마나 적절하게 모여 있는가"를 본다. 너무 좁아서 실제값을 놓쳐도 벌점을 받고, 지나치게 넓어도 벌점을 받는다. QRM 관점에서는 VaR 한 점이 아니라 predictive distribution 전체의 calibration 과 sharpness 를 동시에 평가하는 proper scoring rule 로 이해하면 된다.

2.2 Joint variogram - 자산들이 함께 움직이는 방식이 맞는가

$$\mathbf{VS \approx \Sigma_{(i<j)}\, w_{ij}\,[\,|y_i-y_j|^p - E|X_i-X_j|^p\,]^2}$$

예를 들어 UST 2Y·5Y·10Y·30Y 를 각각 독립적으로 잘 예측해도, 한 draw 안에서 yield curve 가 비현실적으로 꼬이거나 tenor 간 co-movement 가 틀리면 Joint score 가 나빠진다. 이것이 현재 Quant 모델의 가장 큰 약점으로 드러났다.

2.3 Tail penalty - 극단 분위수를 잘 배치했는가

1%, 5%, 95%, 99% 분위수에서 pinball loss 를 계산한다. 따라서 최근 변동성 regime 과 fat-tail 을 잘 반영하는 모델이 유리할 수 있다. 실제로 현재 Quant 모델은 이 항목에서 baseline 보다 뚜렷하게 좋아졌다.

3. 출발점: Reference Gaussian baseline

기존 reference 모델은 과거의 일별 변화량을 이용해 자산별 scale 과 cross-asset correlation 을 추정하고, joint Gaussian shock 을 만들어 h 일 앞의 분포를 생성한다. level target 에서는 현재 수준을 중심으로 두고, horizon 이 길어질수록 √h 로 불확실성을 키우는 고전적인 random-walk 근사에 가깝다.

$$X_{t+h} \approx X_t + \sqrt{h} \cdot D \cdot z, \qquad z \sim N(0,R)$$

D = 자산별 일별 표준편차의 대각행렬, R = 과거 empirical correlation

이 구조의 장점은 단순성과 안정성이다. 특히 UST curve 처럼 tenor 간 correlation 이 강한 경우 empirical correlation + Cholesky 구조가 joint dependence 를 비교적 안정적으로 유지한다.

단점은 시장 regime 변화와 비정규성이다. 최근 volatility 가 급등했는데 20 년 전체 표본의 분산을 그대로 쓰거나, 금융 shock 의 fat-tail 을 Gaussian 으로 처리하면 tail calibration 이 약해질 수 있다. 그래서 Quant candidate 를 만든 목적은 바로 이 부분을 개선하는 것이었다.

Baseline 장점	Baseline 한계
단순하고 재현 가능	최근 volatility regime 반영이 약할 수 있음
cross-asset correlation 구조가 안정적	Gaussian tail 이 금융 데이터에 너무 얇을 수 있음
√h scaling 으로 horizon 해석이 명확	비선형·mean-reversion signal 을 거의 사용하지 않음

4. 우리가 만든 Quant v1 은 무엇이 달라졌나

Quant v1 은 baseline 을 완전히 버린 복잡한 ML 모델이 아니다. 오히려 "변동성은 최근 정보를 더 많이 반영하고, shock 의 모양은 실제 역사적 shock 을 재표본화하고, drift 는 매우 약하게만 허용한다"는 보수적인 probabilistic forecasting engine 이다.

파라미터	현재 값	뜻
recent_window	126	최근 shock pool 에 사용할 영업일 수
recent_mix	0.60	bootstrap block 을 최근 pool 에서 뽑을 확률 60%
ewma_half_life	60	EWMA 가중치의 half-life. "최근 60 일만 사용"이 아님
ewma_weight	0.70	EWMA covariance 70% + long-run covariance 30%
block_length	5	역사적 shock 을 5 일 연속 block 으로 sampling
numeric_drift_shrink	0.20	추정 drift 를 20%만 반영
max_drift_sigma	0.35	drift 크기를 horizon σ 의 0.35 배 이내로 cap
min_pool_rows	30	최소 aligned history 요구

4.1 EWMA volatility: "60 일 window"가 아니라 half-life 60

$$\lambda = \exp[\ \ln(0.5) / 60\ ], \qquad \text{weight}(\text{age}) \propto \lambda^{\text{age}}$$

60 영업일 전의 관측치는 오늘 관측치의 약 1/2, 120 영업일 전은 약 1/4 의 상대 가중치를 갖는다. 즉 데이터를 60 일에서 잘라내는 것이 아니라, 최근 데이터에 더 큰 weight 를 주는 방식이다.

$$\Sigma_\text{blend} = 0.70\ \Sigma_\text{EWMA} + 0.30\ \Sigma_\text{full}$$

그 후 각 자산의 target daily volatility 는 이 blended covariance 의 대각원소에서 가져온다: $\sigma_i = \sqrt{\Sigma_{ii}}$. 중요한 점은 현재 구현에서 이 blended covariance 의 off-diagonal 자체를 simulation dependence 에 직접 강제하지는 않는다는 것이다. 이 점이 다음 버전의 주요 개선 포인트다.

5. Quant v1 의 bootstrap 과 drift 를 쉽게 이해하기

5.1 Multivariate block bootstrap

과거 shock 을 자산별로 따로 뽑지 않는다. 같은 날짜의 여러 자산 shock vector 를 한 행(row)으로 묶어서 동시에 sampling 한다. 따라서 contemporaneous cross-asset structure 는 어느 정도 유지된다.

$$\varepsilon_t = (\varepsilon_{1t}, \varepsilon_{2t}, \ldots, \varepsilon_{kt}) \rightarrow \text{“한 행 전체”를 sampling}$$

v1 에서는 한 번 선택할 때 5 일 연속 block 을 가져온다. 의도는 단기 serial structure 까지 보존하는 것이었다. 하지만 24-fold ablation 에서 block length 를 1 로 줄였을 때 성능이 더 좋아져, 현재 문제에서는 5 일 serial block 이 오히려 noise 또는 과도한 path dependence 를 넣었던 것으로 보인다.

5.2 Recent pool 과 Full-history pool

표준화된 shock pool 을 두 개 만든다. 하나는 전체 역사, 다른 하나는 최근 126 영업일이다. 각 block 을 만들 때 60% 확률로 최근 pool, 40% 확률로 전체 pool 을 선택한다. 이 장치는 “현재 regime 을 더 많이 보되, 최근 6 개월만 맹신하지는 않기” 위한 절충이다.

5.3 약한 mean-reversion / trend shift

$$\text{Future_h} = \beta_0 + \beta_1 \cdot \text{PriorRunup_h} + \text{error}$$

$$\text{Applied shift} = 0.20 \times \text{fitted value}, \ \text{capped at } \pm 0.35 \times \sigma_h$$

level target 에서는 과거 h 일 동안의 run-up 과 그 다음 h 일 변화 사이의 단순 회귀를 적합하고, 예측값의 20%만 centre shift 로 사용한다. QRM 식으로 보면 signal 을 강하게 베팅하지 않고 shrinkage 와 cap 을 건 것이다.
Ablation 결과 drift 제거 효과는 작았으므로 현재 성능의 핵심 병목은 drift 보다 dependence 쪽이다.

6. Walk-forward validation: 우리가 "과거로 돌아가 시험"한 방식

Fold	그 시점까지 사용	예측	그 다음
1	과거 데이터 → origin 1	h 일 앞 분포	실현값과 비교
2	과거 데이터 → origin 2	h 일 앞 분포	실현값과 비교
…	시간을 앞으로 이동	같은 절차 반복	score 누적
24	과거 데이터 → origin 24	h 일 앞 분포	실현값과 비교

한 fold 는 과거 한 날짜를 as-of date 로 잡고, 그 날짜 이후 정보는 보지 않은 채 forecast distribution 을 만든 다음 실제 이후 값과 비교하는 1 회의 pseudo-out-of-sample test 다. 이를 여러 시점에서 반복하면 특정 한 달에 우연히 맞은 모델을 좋은 모델로 착각하는 위험을 줄일 수 있다.

최종 비교에서는 t2-F3-election-2024-joint unit 의 긴 UST history 를 사용해 24 folds, fold 간 spacing 21 business rows, fold 당 1,000 Monte Carlo draws 로 비교했다.

검증 설정	값
Unit	t2-F3-election-2024-joint
Folds	24
Spacing	21 business rows
Monte Carlo draws	1,000 per model per fold
비교 모델 수	7 (reference + 6 Quant variants)
평가	Marginal / Joint / Tail / Composite

검증 과정에서 있었던 기술적 이슈

- 공식 scorer 에서는 quant_out/forecast.parquet 가 admissible=true, g0~g3 pass 를 확인했다.
- 공개 unit 은 sealed realized outcomes 가 없으므로 공식 local scorer 는 실제 leaderboard score 가 아니라 gate 검증만 수행한다.
- Windows 에서 qfbench2-smoke 는 O_NOFOLLOW / O_DIRECTORY 미지원 때문에 실패했으며, 이는 모델 로직 문제가 아니라 플랫폼 filesystem 제약이다.
- 초기 exemplar walk-forward 는 harness 의 panel-path 가정과 exemplar 파일 배치가 맞지 않아 실패했다. 이후 long-history practice unit 에서 research 용 walk-forward 를 수행했다.

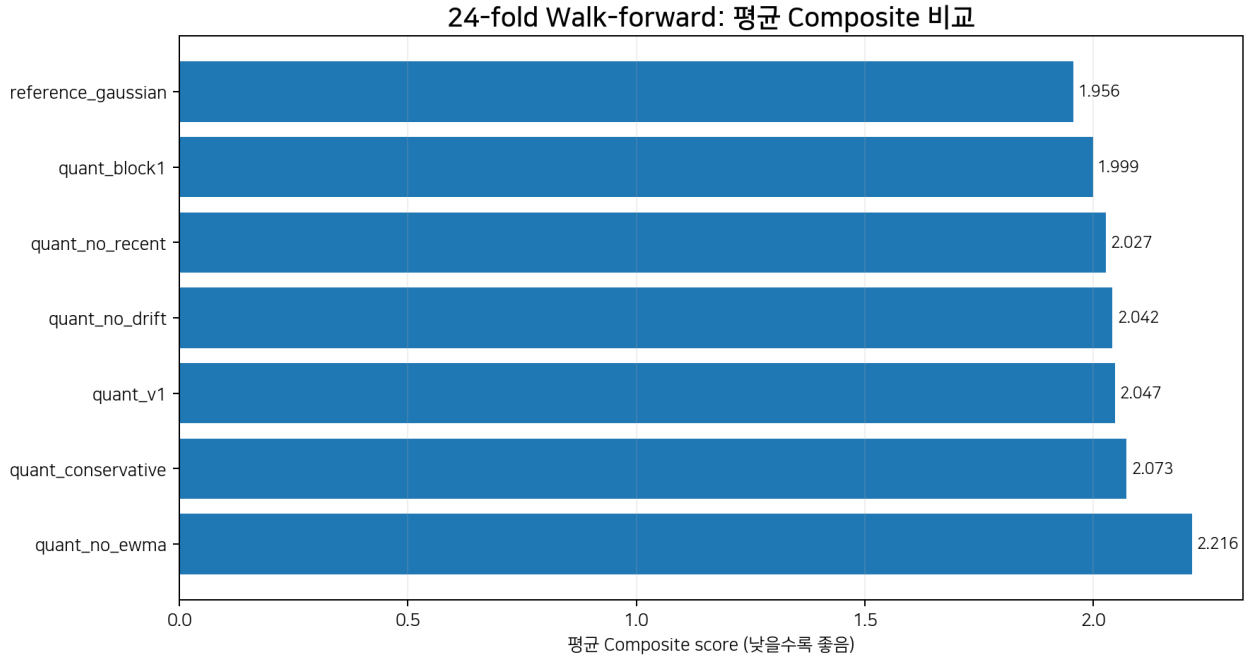
7. Ablation study: 어떤 부품이 실제로 도움이 됐나

Ablation 은 “한 번에 한 요소를 제거하거나 약화해서, 그 요소가 실제로 성능에 기여했는지 확인”하는 실험이다. QRM 에서 sensitivity analysis 또는 nested model comparison 과 비슷한 사고방식으로 보면 된다.

모델	v1 대비 변경	질문
reference_gaussian	기존 Gaussian baseline	전체 기준점
quant_v1	원래 Quant 설정	현재 후보
quant_no_recent	recent_mix = 0	최근 shock pool 이 필요한가?
quant_no_ewma	ewma_weight = 0	최근 volatility weighting 이 필요한가?
quant_no_drift	drift shrink = 0	mean-reversion/trend centre shift 가 필요한가?
quant_block1	block_length = 1	5 일 serial block 이 실제로 도움이 되는가?
quant_conservative	recent=.25, ewma=.40, drift=.10	전체적으로 더 보수적으로 하면 좋아지는가?

이 실험을 통해 단순히 “파라미터를 튜닝해서 점수만 올리는 것”보다, 어떤 구조가 왜 유효한지 확인하려고 했다.

8. 24-fold 결과



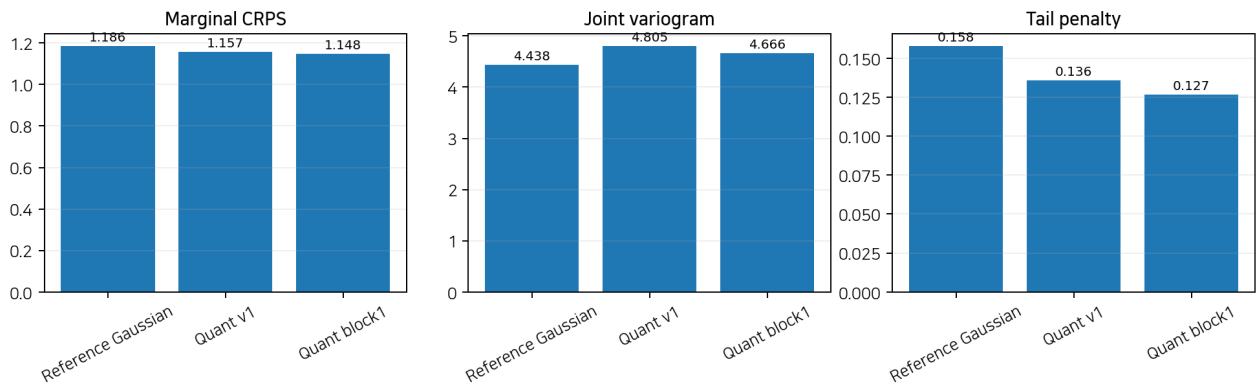
Model	Marginal ↓	Joint ↓	Tail ↓	Composite ↓	Win vs Ref
reference_gaussian	1.1858	4.4381	0.1579	1.9559	-
quant_block1	1.1477	4.6657	0.1268	1.9989	41.7%
quant_no_recent	1.1561	4.7427	0.1316	2.0272	41.7%
quant_no_drift	1.1548	4.7912	0.1349	2.0418	37.5%
quant_v1	1.1568	4.8047	0.1358	2.0470	29.2%
quant_conservative	1.1672	4.8701	0.1411	2.0728	41.7%
quant_no_ewma	1.2046	5.2636	0.1736	2.2161	33.3%

Reference Gaussian 의 평균 Composite 가 1.9559 로 가장 낮았고, Quant 계열 중에서는 quant_block1 이 1.9989 로 가장 좋았다. 즉 현재 best Quant 는 baseline 보다 약 2.2% 높은(나쁜) Composite 를 기록했다.

그러나 component 를 보면 단순 실패가 아니다. quant_block1 은 reference 대비 Marginal 을 약 3.2%, Tail 을 약 19.7% 개선했다. 반면 Joint 는 약 5.1% 악화했다. 30% weight 를 받는 Joint 의 손실이 Marginal 과 Tail 의 이득을 상쇄했다.

9. 결과를 QRM 관점에서 해석하면

어디서 좋아졌고, 어디서 손해를 봤는가



9.1 EWMA volatility 는 유효했다

quant_no_ewma 의 Composite 는 2.2161 로 v1(2.0470)보다 약 8.3% 악화했다. 최근 volatility information 을 제거했을 때 marginal, joint, tail 이 모두 나빠졌다. 따라서 "최근 volatility regime 을 더 크게 반영한다"는 핵심 아이디어는 유지할 가치가 높다.

9.2 5 일 block 은 오히려 과했다

block length 를 5 에서 1 로 줄인 quant_block1 이 v1 보다 Composite 를 약 2.35% 개선했다. contemporaneous multivariate shock vector 는 그대로 유지하면서 serial block 만 제거했기 때문에, 현재 task 에서는 5 일 path dependence 가 추가 정보보다 noise 를 더 많이 전달한 것으로 해석할 수 있다.

9.3 recent pool 과 drift 는 2 차적인 문제

recent_mix 를 완전히 제거한 모델은 v1 보다 약 1.0% 개선했고, drift 를 제거한 모델은 약 0.25% 개선했다. 방향성은 있지만 block length 만큼 강한 효과는 아니다. 따라서 우선순위는 "drift 를 더 정교하게 만들기"보다 joint dependence 를 안정화하는 쪽이다.

9.4 핵심 병목은 covariance 가 아니라 "사용되는 dependence 구조"

코드에서는 Σ_EWMA 와 Σ_full 을 섞은 covariance 를 계산하지만, 최종 bootstrap scale 에 직접 쓰는 것은 주로 대각 원소에서 얻은 자산별 σ 다. cross-asset dependence 는 표준화된 historical row bootstrap 에 의해 간접적으로 결정된다. 즉 volatility model 은 잘 개선됐지만, correlation model 은 별도 통제 없이 bootstrap 표본 선택에 의존한다. 이 구조가 Joint variogram 손실과 연결될 가능성이 높다.

10. “코드에서 뭘 바꾼 건가?”를 통계 모형으로 번역

코드 변경	통계적 의미	결과
EWMA half-life 60	최근 shock 에 더 큰 가중치	유지해야 함. 제거 시 성능 크게 악화
EWMA 70% + Full 30%	단기 regime + 장기 안정성 blend	현재 marginal/tail 개선의 핵심 후보
Recent window 126 / mix 60%	최근 6 개월 shock 을 더 자주 재사용	효과는 제한적; 과도할 가능성
Block length 5	5 일 연속 shock cluster 보존	이번 UST test 에서는 오히려 불리
Block length 1	동시점 cross-asset shock 만 보존	현재 best Quant
Drift shrink 20% + cap	약한 mean-reversion/trend signal	영향 작음
Ablation harness 추가	동일 fold 에서 여러 설정 비교	모델 개선 방향을 데이터로 식별

중요한 점은 “Python 코드를 많이 바꿨다”가 아니라, 모델링 가정 자체를 하나씩 바꾸고 그 경제적·통계적 의미를 실험했다는 것이다. QRM 식으로 보면 volatility estimator, dependence estimator, innovation distribution, conditional mean 의 네 블록을 분리해서 검증한 셈이다.

Forecast distribution = Conditional mean + Volatility scale × Joint shock distribution

현재까지의 결과는 Conditional mean 보다 Volatility scale 은 개선되었고, Joint shock distribution/dependence 가 아직 baseline 보다 불안정하다는 쪽으로 읽힌다.

11. 다음 단계: Quant v2 의 설계 방향

다음 버전은 새로운 복잡한 모델을 추가하기보다, 지금 잘된 부분과 baseline 이 잘한 부분을 결합하는 것이 합리적이다. 핵심은 volatility 와 correlation 을 분리하는 것이다.

$$\Sigma_t = D_t R_t D_t$$

D_t 는 최근 regime 을 빠르게 반영하는 EWMA 기반 volatility, R_t 는 더 긴 표본과 shrinkage 를 이용해 안정적으로 추정한 correlation matrix 로 둔다. 이는 QRM 에서 covariance 를 "volatility × correlation × volatility"로 분해하는 익숙한 접근이다.

Quant v2 구성	계획
Volatility D_t	EWMA + long-run blend 유지
Correlation R_t	long-run + recent/EWMA correlation 을 별도로 blend/shrink
PSD 안정화	eigenvalue floor / nearest-PSD 유지
Innovation	fat-tail historical bootstrap 또는 recolored bootstrap
Block	우선 length = 1
Drift	0 또는 매우 작은 shrinkage 부터 시작
검증	동일 24 folds 에서 reference / block1 / v2 직접 비교

성공 조건

현재 best Quant 의 Marginal 1.1477 과 Tail 0.1268 수준을 크게 잃지 않으면서, Joint 4.6657 을 reference 의 4.4381 근처까지 낮추는 것이 1 차 목표다. 이 정도만 달성해도 Composite 에서 baseline 을 넘어설 여지가 있다.

주의할 점

- 지금의 24-fold 결과는 한 개의 UST cross-asset unit 에서 나온 research diagnostic 이다. Track 2 전체를 대표한다고 볼 수 없다.
- 다음 단계에서는 rates 뿐 아니라 FX, factor-return, 다른 이벤트 시기에도 같은 구조가 안정적인지 확인해야 한다.
- public historical backtest 에 과도하게 맞추면 model-selection overfitting 이 생길 수 있으므로, 파라미터 수를 제한하고 경제적으로 설명 가능한 구조를 유지해야 한다.

12. 지금 상태에서 기억할 핵심 10 줄

1) 제출 형식은 정상이다: 공식 admissibility gate g0~g3 를 통과했다.

2) 60 은 "최근 60 일만 사용"이 아니라 EWMA half-life 60 이다.

3) Quant v1 은 EWMA volatility, recent/full shock mixture, block bootstrap, 약한 drift 를 추가했다.

4) Walk-forward 의 한 fold 는 과거 한 시점에서 하는 pseudo-out-of-sample 모의시험 1 회다.

5) 24 folds 로 reference 와 여러 Quant variant 를 동일 조건에서 비교했다.

6) EWMA 를 없애면 성능이 크게 나빠졌다. 최근 volatility regime 정보는 유효하다.

7) 5 일 block 을 1 일로 줄이자 Quant 성능이 가장 좋아졌다.

8) Best Quant 는 Marginal 과 Tail 에서 reference 보다 좋아졌다.

9) 하지만 Joint variogram 이 나빠 최종 Composite 에서는 아직 reference 가 이긴다.

10) 다음 목표는 "좋은 volatility/tail + 안정적인 correlation"을 결합한 Quant v2 다.

참고: 현재 실험에서 사용한 주요 명령

```
python tools\walk_forward_quant.py `
  --unit units\t2-F3-election-2024-joint `
  --folds 24 `
  --spacing 21 `
  --n-draws 1000 `
  --out research\ust_quant_ablation_24fold.csv
```

본 리포트는 현재 대화에서 확인한 후보 repository 코드, 공식 local gate 출력, walk-forward/ablation 출력에 근거해 작성했다. Public unit 에는 sealed leaderboard realized outcomes 가 없으므로, 여기의 수치는 연구용 pseudo-out-of-sample 비교 결과이며 공식 최종 점수는 아니다.