AGENTHON 2026

Track 2 V7-V8 연구·개발 리포트

레거시 모델의 한계에서 Text-Gated Mixture-of-Experts 전환까지

V7: 레거시 최종·전환 단계
V8: 클린 리셋 아키텍처, Development ablation, 구조적 연구 브랜치

작성 기준일: 2026-10-07

내부 연구 기록 / 재현성 메모

Executive Summary - 핵심 요약

한 줄 결론
V7 단계는 PCA2·GARCH·Copula·EVT·약한 text-tail overlay 를 반복 개선했지만 sealed Development 에서 구조적 우위를 만들지 못했다. V8 은 이를 전면 리셋하고 House text 가 predictive distribution 자체를 움직이는 구조를 시험했으며, Text-ON 은 0.9993 까지 회복했지만 Text-OFF numerical backbone 은 2.4718 로 붕괴했다. 이 결과는 "텍스트가 중요하다"보다 더 구체적으로, 안정적 numerical floor 위에서 text 를 state/model router 로 사용해야 한다는 결론으로 이어졌다.

- V7(본 보고서의 명명): 별도 V7 코드패키지가 보존되어 있지 않아, V6 production + PCA2-only ablation + 전면 리셋 결정을 포함한 "최종 레거시/전환 단계"를 V7 로 정리한다.
- V7 핵심 Development 증거: V6 = 1.0366, PCA2-only = 1.0366. 로컬 pseudo-OOS 개선이 sealed Development 로 전이되지 않았다.
- V8 핵심 구조: 5 일 multivariate block bootstrap, recent/full 60/40, 1,000 joint draws, House 가 scenario probability·shift_sd·vol_scale 을 제공해 전체 joint draw 를 이동/확대.
- V8 Text-ON Development: 0.9993. Baseline 1.0 과 거의 동률로, 이전 1.0366 보다 회복했지만 우수한 edge 는 아니다.
- V8 Text-OFF Development: 2.4718. House 를 제거하면 numerical continuation engine 이 매우 취약하다는 사실이 확인됐다.
- DNS, F2 transfer/router, F4 numerical shock gate, F1 analog sampler 모두 broad/generalizable criterion 을 통과하지 못했다.
- 다음 방향(V9): official/reference-like continuation 을 안정적 floor 로 두고, House 가 text 에서 repricing/shock state evidence 를 추출해 expert distribution 을 soft routing 하는 probabilistic MoE.

버전 명명 주의

프로젝트 아카이브에는 V1-V6 와 V8 Clean Start 가 공식 문서로 남아 있고, 독립적인 V7 패키지나 V7 전용 리포트는 확인되지 않는다. 따라서 본 문서는 사실관계를 유지하기 위해 "V7"을 V8 직전의 최종 레거시/전환 단계로 정의한다. 즉 V6 production, PCA2-only Development ablation, 그리고 2026-10-06 reset 결정을 하나의 V7 단계로 묶는다. 별도의 V7 알고리즘을 새로 만들어 서술하지 않는다.

1. 대회 프레임과 평가 목표

Track 2 는 한 개의 point forecast 가 아니라 수백~수천 개의 Monte Carlo draw 로 미래 joint predictive distribution 을 제출한다. 평가는 Marginal CRPS 50%, Joint Variogram 30%, Tail Penalty 20%의 가중합이며 낮을수록 좋다. 따라서 중심값만 맞히는 모델보다 분포의 폭, 극단부, 그리고 자산 간 공동 움직임을 동시에 맞춰야 한다.

항목	비중	모델링 의미
Marginal CRPS	50%	각 asset-horizon 분포의 위치와 폭
Joint Variogram	30%	동일 draw 안의 cross-asset / cross-horizon 공동 움직임
Tail Penalty	20%	1%·5%·95%·99% 등 극단 quantile 의 calibration

2. V7 - 최종 레거시·전환 단계

2.1 출발점과 모델 철학

V7 단계의 핵심 질문은 "기존 numerical engine 을 더 정교하게 만들면 sealed Development 에서도 우위를 만들 수 있는가?"였다. 이전 V1-V6 에서 EWMA volatility, block bootstrap, PCA yield-curve factors, Student-t/GARCH variants, copula dependence, EVT/POT tail, 그리고 House text-tail overlay 를 차례로 실험했다.

- 강점: 일부 local walk-forward 에서 marginal 과 tail 이 reference 보다 개선되었다.
- 병목: joint variogram 이 자주 악화되어 marginal/tail 이득을 상쇄했다.
- 텍스트 사용법: V4/V6 에서는 text 가 주로 tail mixture weight 를 5-10% 조정하는 약한 overlay 였다.
- 최종 production candidate: PCA2 기반 numerical engine + optional House text-tail 경로.

2.2 검증과 Development 증거

실험/모델	결과	판정
Local PCA2 pseudo-OOS	Reference 대비 약 9% 개선	로컬에서는 유망, sealed 전이 실패
Development V6	1.0366	정규화 1.0 reference 보다 악화
Development PCA2-only	1.0366	V6 와 동일; 약한 text-tail 의 sealed 기여 없음
F4 EVT research	Tail 약 10.4% 개선; Composite 약 0.72% 개선	전체 격차를 줄이기엔 영향 작음
Robust GARCH / copula	대부분 local 0-1% 수준	구조적 개선이 아닌 미세조정

V7 의 결정적 실패
V6 와 PCA2-only 가 sealed Development 에서 정확히 같은 1.0366 을 기록했다. 이는 text-tail overlay 가 실제 leaderboard 분포를 움직이지 못했고, local pseudo-OOS relative ranking 을 sealed Development ranking 으로 외삽하면 안 된다는 강한 증거였다.

2.3 V7 에서 남긴 교훈

- Numerical complexity 가 predictive information 보다 앞서면 GARCH-t/GJR-t 처럼 parameter instability 가 성능을 지배할 수 있다.
- PCA·copula·EVT 를 조금씩 조정하는 방식은 component 개선은 만들 수 있어도 leaderboard 격차를 설명하지 못했다.
- Text 는 tail 장식이 아니라 분포의 centre, width, regime/state transition 자체를 바꾸는 상위 signal 이어야 한다.
- Development submission 은 0.x% local tweak 가 아니라 forecast distribution 을 구조적으로 바꾸는 가설에만 사용해야 한다.

3. V8 - Clean Reset 과 새로운 predictive mechanism

3.1 리셋 원칙

2026-10-06 V8 은 공식 repository 원본에서 완전히 새로 시작했다. V1-V6/PCA/GARCH/EVT/Copula 코드는 research archive 로만 남기고 production backbone 으로 import 하지 않았다. 재사용한 것은 I/O, cutoff/horizon semantics, output schema, Docker/packaging, House API client 같은 plumbing 뿐이었다.

3.2 최초 제출 V8 아키텍처

블록	V8 v0 구현
Numerical generator	Multivariate 5-day block bootstrap
Regime blend	최근 252 개 관측 60% + full history 40%
Draws	1,000 coherent joint trajectories
House output	1-4 scenarios + probabilities + asset 별 shift_sd + vol_scale
Joint coherence	같은 draw index 가 하나의 market scenario; 여러 asset/horizon 공유
Family prompts	F1 continuation / F2 regime shift / F3 cross-asset / F4 tail-shock 특화
Fallback	House 미사용 시 continuation p=1, shift=0, vol=1

$$P(Y) = \Sigma_s \, p_s \cdot P_s(Y \mid \text{numerical history, shift_sd, vol_scale})$$

3.3 구조적·엔지니어링 검증

- 공개 practice unit 103 개(예제 제외) text-OFF 구조 검증: 103/103 통과.
- g0-g3 gates, finite output, row count, cutoff semantics 확인.
- Docker linux/amd64 build 및 network-disabled 실행 확인.
- Mock House ablation 으로 reasoning_applied 와 distribution change plumbing 확인.
- 이 단계의 목적은 정확도 증명이 아니라 재현 가능한 submission infrastructure 검증이었다.

3.4 Development 결과: Text-ON 과 Text-OFF

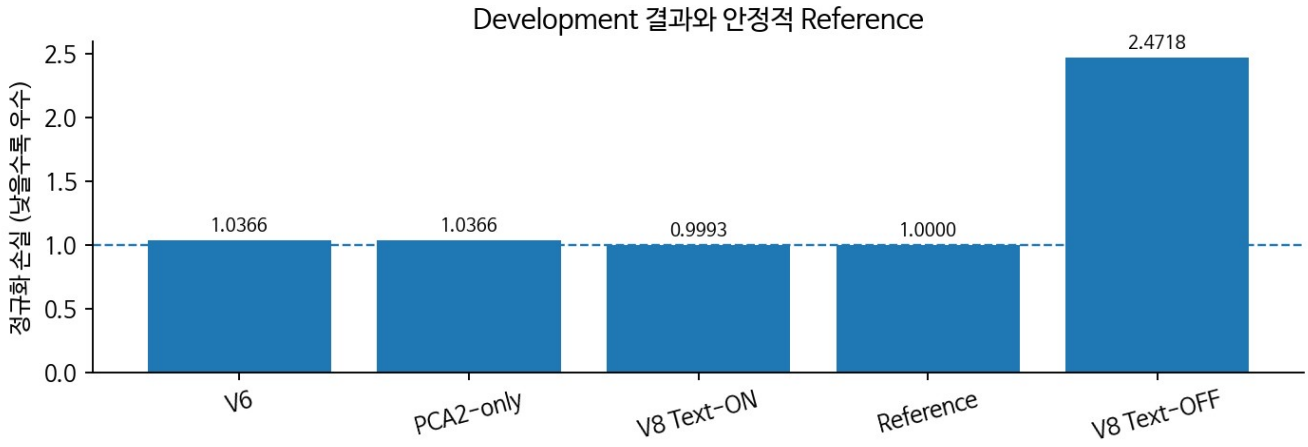


Figure 1. 표시 Score 의 부호를 제거한 정규화 loss 비교. 낮을수록 좋음.

제출	Leaderboard 표시	해석용 loss	핵심 의미
V6	-1.0366	1.0366	Legacy final candidate; reference 보다 악화
PCA2-only	-1.0366	1.0366	Text-tail 효과 없음
V8 Text-ON	-0.9993	0.9993	Reference 수준 회복; 뚜렷한 edge 는 아님
V8 Text-OFF	-2.4718	2.4718	Numerical continuation backbone 붕괴

핵심 해석
Text-OFF 2.4718 을 보고 "text 가 1.47 의 alpha 를 만들었다"고 해석하면 과하다. 더 직접적인 해석은 V8 numerical backbone 이 매우 약했고, House 가 centre/width/scenario 를 크게 움직이며 그 약점을 보정했다는 것이다. 따라서 다음 모델은 V8 OFF 를 continuation expert 로 쓰면 안 된다.

3.5 V8 구조적 연구 브랜치

브랜치	가설	핵심 결과	판정
DNS v0	UST Level/Slope/Curvature factor bootstrap	대부분 0.x% 수준; cut-sizing 에서 Variogram 약 10 배 악화	Reject
F2 static transfer	G10 -> sparse EM target ridge transfer	CNY/INR 일부 5-50% 개선, BRL 악화	Partial
F2 state/router	raw/static/state 를 historical fold 로 routing	Mean 0.8865 이나 median 1.0000, holdout win 16.7%	Reject

F4 shock gate	numeric state -〉 p_shock -〉 normal/shock mixture	15 개 중 strong 0: median Tail 1.0112, CRPS 1.0057	Reject
F1 analog	현재 state 와 유사한 historical origins conditional sampling	20 개 median ratio 1.0379, unit win 25%, strong 4/20	Reject

3.6 브랜치별 해석

- DNS: 경제적으로 해석 가능한 curve factor representation 자체는 매력적이지만, fixed-λ factor-change bootstrap 은 raw tenor history 보다 안정적으로 우월하지 않았다.
- F2 transfer: cross-market 정보원이 특정 regime 에서 매우 강할 수 있다는 증거는 있었다. 그러나 CNY stress 의 큰 평균 개선은 temporal holdout 에서 사라졌고, 일반화 가능한 router 를 만들지 못했다.
- F4 shock gate: numerical state 변수만으로 shock 발생확률을 예측하는 방식은 broad solution 이 아니었다. 특히 일부 funding-stress unit 에서 tail loss 가 크게 악화됐다.
- F1 analog: 비슷한 과거 상태를 찾는 nonparametric idea 는 일부 카드에서 10-20% 개선했지만 전형적 unit 에서는 오히려 악화했고 worst-fold instability 도 컸다.
- 공통 패턴: 같은 numerical history 를 다른 방식으로 재배열·재표현하는 것만으로는 sealed Development 에 필요한 큰 정보 차이를 만들지 못했다.

4. V7 과 V8 의 비교

차원	V7	V8	결론
출발 방식	기존 numerical stack 의 점진적 refinement	공식 repo 에서 clean reset	V8 이 model-selection overfit 위험을 줄임
Text 역할	tail weight 를 약하게 조정	scenario probability·centre·width 를 직접 변화	Text 영향력은 V8 에서 훨씬 큼
Numerical backbone	PCA2 / GARCH / copula / EVT 계열	5-day multivariate block bootstrap	V8 OFF 결과로 backbone 취약성 확인
Development	1.0366	Text-ON 0.9993 / OFF 2.4718	ON 은 회복, OFF 는 붕괴
연구 결론	숫자모델 미세조정 한계	숫자 재배열만으로도 일반화 실패	안정적 floor + text state routing 필요

5. V8 에서 V9 로: Text-Gated Probabilistic Mixture-of-Experts

V8 의 가장 중요한 결과는 House 가 distribution 을 크게 움직일 수 있다는 점과, 동시에 V8 numerical continuation 이 standalone baseline 으로 부적절하다는 점을 동시에 보여준 것이다. 따라서 V9 는 "좋은 baseline 을 House 가 고친다"가 아니라 "안정적 baseline 을 기본 배당으로 두고, text 가 새로운 정보가 있을 때만 다른 expert distribution 으로 확률질량을 이동한다"는 구조로 전환한다.

$$P(Y \mid H,T) = \pi_C(H,T)\, P_C(Y \mid H) + \pi_R(H,T)\, P_R(Y \mid H,D) + \pi_S(H,T)\, P_S(Y \mid H,D)$$

Expert	역할	V9 v0 원칙
Continuation	평상시 안정적 floor	official/reference-like joint forecast
Repricing	정책·인플레·성장 정보에 따른 중심 재가격화	text 방향과 일치하는 historical joint repricing events
Shock	희귀·극단 상태	text 가 shock activation 판단, history 가 shock magnitude/shape 제공

- House 는 exact bp/%나 mixture probability 를 직접 예측하지 않는다.
- House 는 repricing_evidence, shock_evidence, direction, affected assets, confidence 를 구조화한다.

- 실제 mixture weight 는 deterministic router 가 계산한다.
- 각 draw 는 하나의 global expert state 를 선택해 모든 asset/horizon 에 공유한다.
- 검증은 Continuation-only vs Static MoE vs Text-Gated MoE 의 3-way ablation 으로 수행한다.

6. 최종 연구 교훈과 운영 원칙

1. Local pseudo-OOS 는 아이디어 필터이지 sealed Development 의 대리점수가 아니다.
2. 0.x% 개선은 제출 근거가 아니라 robustness 신호로만 취급한다.
3. Text 효과를 검증할 때 numerical baseline 이 자체적으로 안정적이어야 한다.
4. Text 는 숫자 prediction 자체보다 market-state inference 와 model routing 에 쓰는 편이 더 검증 가능하다.
5. Mixture model 에서는 expert 예측을 elementwise 평균내지 말고 draw-level categorical mixture 로 multimodality 를 보존한다.
6. F3 를 위해 동일 draw 의 macro state 는 모든 asset/horizon 에서 공유되어야 한다.
7. 실패한 branch 는 parameter rescue 를 반복하지 않고 archive 해 중복 실험을 막는다.
8. 다음 Development 제출은 "reference-like floor + text-gated expert routing"이 구조 검증과 ablation 을 통과할 때만 수행한다.

Appendix. 실험 타임라인과 핵심 수치

날짜	이벤트	핵심 수치	결론
2026-10-06	V6 Development	1.0366	Legacy production candidate
2026-10-06	PCA2-only Development	1.0366	Text-tail no sealed effect
2026-10-06	V8 clean reset	-	Legacy numerical family retired
2026-10-07	V8 Text-ON Development	0.9993	Recovered to reference level
2026-10-07	F2 router holdout	median 1.0000	Win rate 16.7%; reject
2026-10-07	F4 shock gate	median tail 1.0112	0/15 strong; reject
2026-10-07	F1 analog	median 1.0379	Unit win 25%; reject
2026-10-07	V8 Text-OFF Development	2.4718	Numerical backbone rejected
2026-10-07	V9 design frozen	-	Reference continuation + text-gated Repricing/Shock

내부 근거 자료

- Agenthon_T2_Retrospective_Reset_2026-10-06.pdf
- 00_Agenthon_T2_V8_Clean_Start_Handoff.pdf
- Agenthon_T2_F1-F4_Model_Ideas_and_Papers.pdf
- V8 DNS / F2 Transfer / F4 Shock Gate / F1 Analog experiment outputs, 2026-10-07
- CodaBench Development submissions: V6, PCA2-only, V8 Text-ON, V8 Text-OFF
- Official Track 2 public repository and qfbench2-common 2.4.4 rules

재현성 주의
본 보고서의 "V7"은 독립적인 보존 패키지가 아니라 V8 직전의 최종 레거시/전환 단계를 가리킨다. 이는 아카이브에 없는 별도 V7 모델을 만들어내지 않기 위한 명시적 명명 규칙이다.