Agenthon 2026 Track 2
V13

WIDTH085 – global uncertainty shrink inside the V11 production path

Sealed score	V11 reference	Delta vs V11	Status
−2.3287	−2.2219	−0.1068	REJECTED

Local median improvement를 믿고 15% global width shrink를 production에 적용한 실험

Executive conclusion

V13은 pseudo-OOS에서 WIDTH085가 E2 대비 낮은 median composite를 보인 점을 활용해, V11의 text scenario mixture에 0.85 global width shrink를 적용한 제출이었다. sealed Development score는 -2.3287로 V11(-2.2219)보다 0.1068 낮아 명확히 열위였다. 특히 local screen에서 이미 mean과 worst-case가 매우 불안정했기 때문에, 이 결과는 median-only calibration gain을 production edge로 해석하면 안 된다는 교훈을 남겼다.

1. 왜 0.85를 시도했나

Local candidate	Median vs E2	Mean vs E2	Win	P90	Worst
WIDTH085	0.9417	1.2900	69.2%	1.1781	85.2490
CONDGEN20	0.9984	1.0110	50.6%	1.0789	3.5633
E2	1.0000	1.0000	baseline	1.0000	1.0000

- WIDTH085는 480 pseudo-OOS folds에서 median 0.9417로 가장 강한 중앙값 개선을 보였다.
- 그러나 mean 1.2900, worst 85.249로 tail instability가 매우 컸다.
- 특히 F1에서 median 0.9057이지만 mean 1.8668, worst 85.249로 "평소엔 좋지만 일부 fold에서 붕괴"하는 패턴이 뚜렷했다.
- F4는 상대적으로 안정적이어서 median 0.9437, mean 0.9685였지만 family 간 편차가 컸다.

Important distinction

위 local WIDTH085 screen은 pure numeric/E2 비교였다. V13 production은 V11 text scenario mixture 위에 0.85 shrink를 얹은 것이므로 동일한 실험이 아니다. local 결과를 sealed production 성능으로 직접 전이하면 안 된다.

2. Production change

V11 E2 90/10 base → V8 House scenarios → scenario centre + vol transform → global width x 0.85 → final V13 joint forecast

- 핵심 변경은 uncertainty scale 하나. V11의 scenario representation과 House logic은 유지.
- 의도: local calibration 결과에서 보인 over-dispersion을 줄여 CRPS / tail component를 개선.
- 위험: scenario-specific width transform 뒤에 다시 global shrink를 적용하면 text가 만든 tail / regime uncertainty까지 함께 축소될 수 있음.

3. Sealed Development result

Submission ID	Submitted	Score	V11 gap
977943	2026-10-11 23:21	-2.3287	-0.1068

Search... Status

ID #	File name	Date	Status	Score
980088	submission_width090_dev.zip	2026-10-12 18:01	Finished	-2.7100
977943	submission_v13_width085_01.zip	2026-10-11 23:21	Finished	-2.3287
977123	submission_v11_e2_v8_01.zip	2026-10-11 19:23	Finished	-2.2219
975140	submission_v10_dirsoft_01.zip	2026-10-11 01:40	Finished	-2.4649
969548	submission_v9_REAL.zip	2026-10-09 00:02	Finished	-2.7325
969394	submission_v9_REAL.zip	2026-10-08 22:56	Failed	

Codabench submission history: V13 WIDTH085 -2.3287, V11 -2.2219, WIDTH090 -2.7100.

4. 결과 해석

관찰	판정
V13 -2.3287 < V11 -2.2219	sealed 기준에서 명확한 열위
Local median 0.9417	중앙값 개선 자체는 실제 존재
Local mean 1.2900 / worst 85.249	tail instability 경고가 production에서 무시되면 안 됨
F1 catastrophic folds	global shrink의 family-agnostic 적용이 위험
Text scenario + shrink	numeric calibration을 text-transformed distribution에 그대로 이식하는 것은 별도 검증 필요

Main lesson

Pseudo-OOS median만으로 production calibration을 선택하지 않는다. Mean / P90 / worst / family stability가 동시에 지지하지 않는 global width patch는 sealed candidate로 승격시키지 않는 것이 맞았다.

5. 후속 영향

- V13 실패 이후 "상황별로 어떤 model/width를 선택할 수 있는가"를 보기 위해 unified tournament와 router 분석을 진행.
- Oracle router upper bound는 존재했지만, history length / effective-N / numeric state로 expert winner를 안정적으로 예측하지 못함.
- 그 결과 V11 내부를 더 복잡하게 routing하는 방향보다, 공식 Gaussian을 처음부터 다시 해부하는 reset branch로 이동.

6. 최종 상태

Final decision V13 WIDTH085 rejected. Production champion은 계속 V11. WIDTH085 자체는 후속 Gaussian reset의 calibration diagnostic으로만 남기고 V11 patch로는 폐기.

Decision ledger

질문	V13이 남긴 답
Width shrink 자체에 local signal이 있었나?	YES - median 기준으로는 분명한 개선
그 signal이 robust했나?	NO - mean / worst / F1 tail이 불안정
V11 위에 그대로 이식해도 됐나?	NO - sealed score에서 명확히 악화
추가 0.80/0.90 미세조정이 합리적이었나?	V13 기준으로는 NO - 새로운 independent evidence 필요
Champion 변경?	NO - V11 -2.2219 유지

Sealed comparison at this stage

Candidate	Score	Gap vs V11	Status
V11 E2 + V8 scenario	-2.2219	baseline	CHAMPION
V13 WIDTH085	-2.3287	-0.1068	REJECT
V10 dirsoft	-2.4649	-0.2430	REJECT

Source note Local WIDTH085 pseudo-OOS 수치는 unified model tournament 출력에 근거. Sealed score / submission ID / date는 user-supplied Codabench history screenshot에 근거.