Agenthon 2026 Track 2 V11

E2 90/10 Numeric Backbone + V8 Text Scenario Mixture

Sealed score	Status	Record date
-2.2219	Finished	2026-10-11

검증된 numeric backbone 과 sealed-positive text representation 을 결합한 최종 하이브리드 후보

Executive conclusion

V11 은 V10 의 방향 분류를 폐기하고, V8 에서 실제 sealed 효과가 확인됐던 scenario probability + centre shift + volatility scaling 을 E2 90/10 backbone 위에 이식했다. Sealed score -2.2219 로 V8 Text-ON(-2.2382)을 명목상 0.0163 개선하며 현재 식별 가능한 제출 중 최고점을 기록했다. 다만 이 차이는 관찰된 run-to-run 변동 범위보다 작아 구조적 우위가 확정됐다고 보기는 어렵다.

1. 설계 원칙

- 새로운 아이디어를 더 추가하지 않고, 이전 실험에서 살아남은 두 구성요소만 결합했다.
- Numeric: V10 에서 고정한 E2 empirical joint-row + EWMA60 90/10 current volatility.
- Text: V8 에서 sealed Text-ON 이 Text-OFF 보다 크게 개선됐던 1~4 scenario mixture.
- V9 hard switching, V10 directional soft tilt, lexical retrieval 은 모두 제외했다.

E2 90/10 base draws → V8 House scenarios → one scenario per joint draw → shift + width transform → final joint forecast

2. Numeric backbone

Level step	$\Delta P_t = P_t - P_{t-1}$
Standardization	$z_t = (\Delta P_t - \mu_{full}) / \sigma_{full}$
Current volatility	sqrt(0.90 × EWMA60 variance + 0.10 × full variance)
Joint dependence	같은 날짜의 standardized multi-asset vector 를 함께 샘플링
Serial dependence	day-by-day iid row sampling; block serial pattern 은 사용하지 않음
Nested horizons	한 simulated daily path 를 누적해 모든 horizon 에서 공유
Log-return cards	기존 log_return semantics 유지
Monthly cards	공식 reference monthly fallback 유지

3. V8 scenario engine 의 이식

House task	dated corpus 에서 1~4 개의 forward scenario 추출
Scenario weight	각 scenario 의 probability
Centre	asset 별 shift_sd: longest-horizon numeric sd 단위의 중심 이동
Width	asset 별 vol_scale: stochastic deviation 을 scenario 별 확대/축소
Joint consistency	한 draw 전체에 하나의 scenario 를 적용해 cross-asset narrative 보존
Short horizons	shift_sd 효과를 h / max_h 로 선형 축소
Fallback	House 실패 시 continuation(shift=0, vol=1)으로 numeric E2 그대로 사용

V8 에서 되살린 핵심
텍스트를 단일 방향 변수로 압축하지 않는다. continuation / transition / shock 등 여러 상태가 동시에 존재할 수 있고, 각 상태가 centre 와 width 를 함께 바꾸도록 둔다.

4. Structural validation

검증	결과	확인 내용
Local smoke	PASS	E2 engine + scenario transform 연결
Practice batch	206 / 206 PASS	103 units × OFF/mock ON, 전부 gates 통과
Docker build	PASS	linux/amd64
Interface	2.0	qfbench2 contract label 확인
Docker OFF/ON	PASS	mock scenario 적용 시 output 변화 확인

5. Level representation 최종 확인

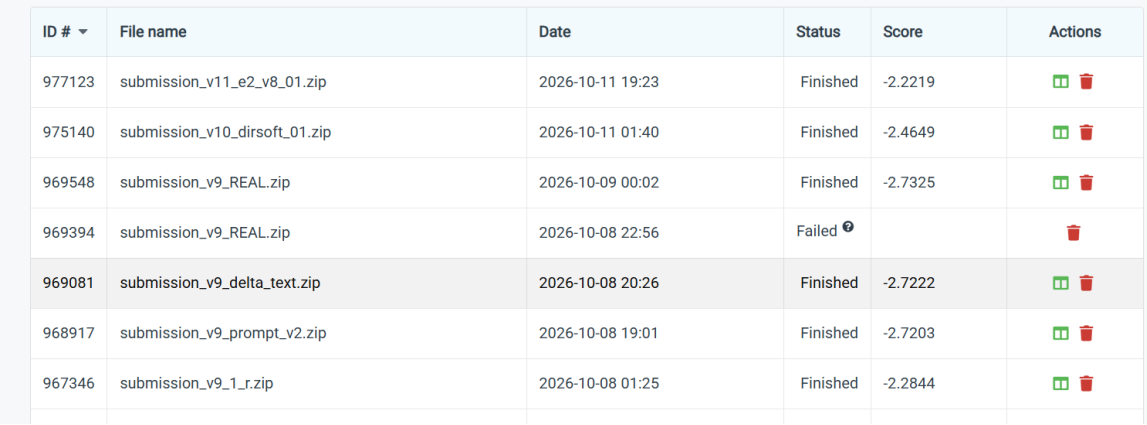
항목	REL / ABS	판정
Median CRPS	1.0035	ABS 우세
Median Variogram	1.0000	동률
Median Tail90	1.0359	ABS 우세
Median Proxy	1.0084	ABS 우세

REL unit win rate	40.0%	불충분
Strong REL units	2 / 80	불충분

Representation decision
Daily level cards 는 log-relative change 가 아니라 현재의 absolute daily change ΔP 를 유지한다. 80 units / 400 pseudo-OOS folds 에서 REL 의 broad advantage 가 나타나지 않았다.

6. Sealed result

버전	Score	V11 대비 차이
V11 E2 + V8	-2.2219	baseline
V8 Text-ON	-2.2382	-0.0163
V10 dirsoft	-2.4649	-0.2430
V8 Text-OFF	-2.4718	-0.2499

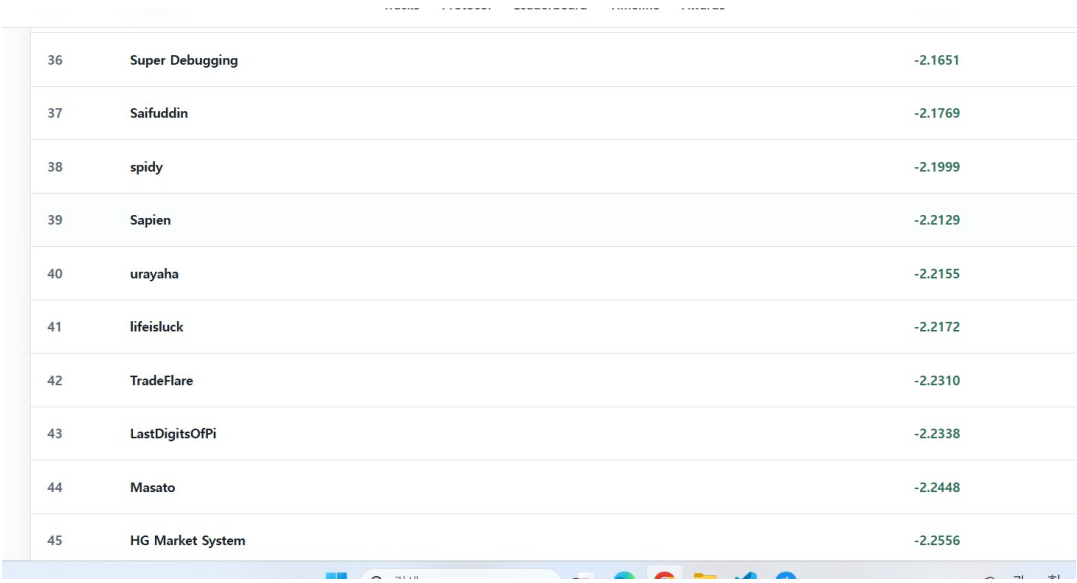


ID #	File name	Date	Status	Score	Actions
977123	submission_v11_e2_v8_01.zip	2026-10-11 19:23	Finished	-2.2219	
975140	submission_v10_dirsoft_01.zip	2026-10-11 01:40	Finished	-2.4649	
969548	submission_v9_REAL.zip	2026-10-09 00:02	Finished	-2.7325	
969394	submission_v9_REAL.zip	2026-10-08 22:56	Failed		
969081	submission_v9_delta_text.zip	2026-10-08 20:26	Finished	-2.7222	
968917	submission_v9_prompt_v2.zip	2026-10-08 19:01	Finished	-2.7203	
967346	submission_v9_1_r.zip	2026-10-08 01:25	Finished	-2.2844	

Codabench submission history - V11 sealed score -2.2219 and V10 -2.4649

Score interpretation. 현재 score 는 높을수록(0 에 가까울수록) 좋다. V11 은 V8 대비 명목상 개선됐지만 +0.0163 은 이전에 관찰된 동일 이미지 run-to-run 변동(~0.046 또는 그 이상)보다 작다. 따라서 "확실한 모델 개선"보다는 "V8 수준을 보존하면서 nominal best 를 기록"한 결과로 보는 편이 보수적이다.

7. Public leaderboard snapshot



36	Super Debugging	-2.1651
37	Saifuddin	-2.1769
38	spidy	-2.1999
39	Sapien	-2.2129
40	urayaha	-2.2155
41	lifeisluck	-2.2172
42	TradeFlare	-2.2310
43	LastDigitsOfPi	-2.2338
44	Masato	-2.2448
45	HG Market System	-2.2556

Agenthon public leaderboard snapshot supplied by user - lifeisluck rank 41, displayed score -2.2172

화면 간 점수 차이

개별 Codabench submission row 는 V11 -2.2219 를 표시하고, 같은 시점의 public leaderboard 화면은 team lifeisluck 에 -2.2172 를 표시한다. 이 문서는 두 화면을 그대로 기록하며, 서로 다른 값의 내부 집계/표시 원인은 별도 근거가 없어 단정하지 않는다.

8. 결과 해석

- V10 에서 사라졌던 text edge 가 V11 에서는 다시 회복됐다. V10(-2.4649) 대비 +0.2430 의 큰 개선은 text representation 선택이 중요했음을 강하게 시사한다.
- E2 backbone 으로 교체해도 V8 scenario representation 의 성능이 무너지지 않았다는 점은 numeric 과 text 역할 분담 원칙과 일치한다.
- 다만 V8 대비 개선폭은 작기 때문에 "E2 가 V8 numeric 보다 확실히 우월했다"는 sealed 결론까지 내리기는 어렵다.
- ABS vs REL screen 에서는 현재 ΔP representation 을 유지할 근거가 확보됐다. numeric representation 과 scale tuning 은 여기서 종료한다.

Final modeling principle

NUMERIC 은 plausible distribution 의 폭·joint dependence·empirical shape 를 담당하고, TEXT 는 그 분포를 scenario probability·centre·width 로 조건부 재구성한다. 텍스트를 단일 방향 변수로 지나치게 압축하지 않는다.

9. 최종 상태

Production candidate	V11 E2 90/10 + V8 scenario mixture
Sealed submission	submission_v11_e2_v8_01.zip
Image digest	sha256:6b10442fe81b10461ce56066ea573238842ff66bed9bce83faa5e35c05d68bc6
Submission ID	977123
Sealed score	-2.2219